

סיכום עבודה - דאטאטון

Time Series



בחלק הזה פילטרנו את הנתונים שיהיו בין 1/7/24 והלאה ושמרנו רק את השורות שהסטטוס שלהן היה required ע"מ לסנן רק את הדרישות.




המטרה - חיזוי כמות דרישות לשבוע על בסיס X שבועות אחורה.




השיטה הראשונה שבדקנו זה ממוצע נע, בחנו חלון זמנים בין שבועיים לשישה שבועות אחורה כאשר המשקל שיש לכל שבוע נקבע על פי הנוסחה הבאה:




```
weights = np.arange(1, window + 1)
weights = weights / weights.sum()
```


להלן התוצאות:











השוואת הריצות על בסיס 2^R :

	2w	3w	4w	5w	6w
ניקיון تنظيف	0.9263854763	0.8295800599	0.7324123811	0.6149140586	0.5332718006
יעוץ	0.8324219525	0.6889368052	0.6281358689	0.5552840713	0.4991685823
תפוס	0.8739667155	0.7178589017	0.6034314738	0.5114719121	0.445439799
בדיקת דם	0.8582644617	0.7024000911	0.5855701821	0.484620423	0.4301097538
בדיקת אק"ג	0.7822318651	0.6257030295	0.5314692304	0.4451995685	0.3497701489
כח עזר - שונות	-5.318658281	-0.3511659808	-0.2467647059	0.3048888889	-0.1696428571
כח עזר - סיוע למטופל	0.8982546567	0.7184697238	0.6863326326	0.4821435612	0.2138039907
כח עזר - אוכל	0.9573201541	0.8701288478	0.6632542455	0.7328582202	0.5950401219
כביסה	0.8639299067	0.6783561583	0.7667365683	0.7030828065	0.5932552111
נקיון - החלפת פרגוד	0.8281864267	0.7324953797	0.6923109244	0.6361301622	0.6135936199
נקיון - בידוד	0.9302083333	0.8833125892	0.8360274948	0.8027014208	0.7165928958
בדיקת רופא	0.8677552233	0.7082156777	0.5950875465	0.5071117261	0.4440816305

אפשר להתרשם שהחלופה הטובה ביותר היא ממוצע נע על בסיס שבועיים אחרונים עם תוצאות ד"י טובות בטיב החיזוי (למעט קטגוריית "כח עזר - שונות")


בחנו גם מודלי ARIMA ו exponential smoothing אבל הם לא הניבו תוצאות טובות.

דרך נוספת אשר ניסינו לתקוף את הבעיה, חיזוי כמות מטלות ברמה יומית לכל חדר.

שיטות:

(1) Prophet כלי חיזוי עיקרי

(a) דרך זו הסתדרה עם מציאת העונתיות אך לא הסתדרה במציאת פיקים או תנודתיות גם לאחר הקצנת הייפר פרמטרים.






(2) Prophet + Sarima Ensemble

(a) מטרת Prophet הייתה מציאת עונתיות (צבר הבקבוק בו נתקלנו בשיטה הראשונה בה Prophet היה כלי החיזוי העיקרי) ומטרת SARIMA הייתה לחסות על פערי הפיקים התנודתיות בחלונות הזמן הצרים יותר.

(b) במקרה הזה סיננו את הTS לרזולוציה של חדר ודרישה, וניתחנו את הTS של כל קומבינציה כזו בנפרד.

(c) שלב ENSEMBLE כולל איחוד החיזויים משני המודלים בעזרת WEIGHTED AVERAGE.








למרות שהתוצאות לא היו עקביות לכלל החדרים (בשל רידוד הדאטה רק לדרישות וחלון זמן של חצי שנה) ניתן לראות כי קיימת אפשרות חיזוי כמות מטלות ברמת חדר על בסיס יומי.


מכאן נפתח פוטנציאל לחלוקת כח אדם מדויקת יותר ברמת מחלקות וחדרים ומטלות.

בחנו כמה מודלים, בסוף המודל הטוב ביותר היה XGBOOST (לא היה יותר מדי זמן להריץ GRIDSEARCH כמו שצריך אז אולי אפשר לשפר את החיזויים קצת יותר) ונתן את התוצאות הבאות:

תוצאות לא מזהירות למעט הדיוק של ה"תפוס" ששם יש תוצאות יחסית טובות (דיוק של 73% בהסתמך על פיצ'רים של יום בשבוע ומספר חדר בלבד!)







מטרה:

המטרה של העבודה הייתה לפתח מודל לחיזוי זמן, מילוי בקשות, בחדרי המיון, תוך חלוקת הזמנים לקטגוריות זמן שונות (באקטים). המודל נועד לאפשר חיזוי טווח זמן ולאחר מכן חיזוי מדויק של הזמן, כדי לתמוך בחישוב עומסי זמנים ולשפר את ניהול המשאבים בבית החולים.

לוגיקה כללית:

עבור כל בקשה, חושב הזמן שנדרש למילוייה (בדקות) על ידי השוואת זמן הדרישה לזמן הסיום, תוך וידוא שהתהליך התבצע בסדר הנכון. נבדקו דפוסים שונים בזמני המילוי, וזוהו ערכים חריגים על בסיס גבולות סטטיסטיים (1% התחתון ו-99% העליון). החריגים סומנו והוצאו.


נוספו מאפיינים מגוונים כדי לחזק את היכולת לחזות:

מאפיינים זמניים: שעה ביום, יום בשבוע, האם סוף שבוע, וקידוד סינוסי לשעות וימים.

מאפייני עומס: מספר הבקשות הפעילות בחדר או במחלקה.

```
# Define feature columns
categorical_cols = ['room', 'requirement', 'day_of_week', 'hour_of_day', 'minute_of_hour']
numerical_cols = [
    'avg_fulfillment_same_req_past_hour',
    'avg_fulfillment_same_room_past_hour',
    'avg_fulfillment_same_room_past_week',
    'avg_fulfillment_same_room_same_day',
    'avg_fulfillment_same_req_all_rooms_same_day',
    'avg_fulfillment_same_room_same_week',
    'avg_fulfillment_same_req_all_rooms_same_week'
```

מאפיינים סטטיסטיים: ממוצעים של זמני מילוי קודמים לחדרים, לבקשות ולשילובים של חדרים ובקשות. נתונים עם מעט מדי דוגמאות (פחות מ-50) סוננו כדי להפחית שיבושים.

**חלוקה לקטגוריות**

זמני המילוי חולקו לקבוצות לפי גבולות מוגדרים מראש (למשל, 0-10 דקות, 10-30 דקות, 30-90 דקות), ונבדקו חלוקות שונות עם 3, 4, 5 או 6 קטגוריות.

פיתוח מודלים לחיזוי

האימון כלל שני שלבים:

1. **סיווג באקטים**: נעשה שימוש במודל LGBMClassifier כדי לחזות את טווח הזמן (באקט) שבו הבקשה תתמלא. המודל אומן על הנתונים לאחר חלוקה לקטגוריות, תוך שימוש ב GridSearchCV- לכוונון היפר-פרמטרים.
2. **חיזוי זמן מדויק**: בתוך כל באקט, אומן מודל LGBMRegressor נפרד לחיזוי הזמן המדויק. גם כאן בוצע כוונון היפר-פרמטרים באמצעות GridSearchCV, תוך מזעור שגיאת RMSE. השילוב של שני השלבים מאפשר חיזוי דו-שלבי: תחילה זיהוי הטווח (למשל, "נמוך" או "גבוה"), ולאחר מכן חיזוי הזמן המדויק בתוך הטווח.


השוואת גישות




נבדקו ארבע גישות שונות (עם 3, 4, 5 או 6 קטגוריות). הגישה עם 4 קטגוריות נבחרה כטובה ביותר מבחינת שגיאה הכי נמוכה, התוצאות על כל החדרים וכל הדרישות לא גבוה, אבל כן יש מספר מסויים של חדרים ודרישות שהראו תוצאות חיזוי יפה.


חיבור לפרקטיקה:



המודל מאפשר חיזוי דו-שלבי שמתאים לניהול עומסים בבית חולים. בשלב הראשון, חיזוי הטווח (למשל, "בקשה תתמלא תוך פחות מ-10 דקות" או "מעל 90 דקות") נותן הערכה ראשונית מהירה של משך הזמן הצפוי, מה שמסייע בתכנון מידי של משאבים כמו כוח אדם או חדרים. בשלב השני, חיזוי הזמן המדויק (למשל, 7 דקות בתוך טווח "נמוך") מאפשר חישוב מדויק יותר של עומסי זמנים, כגון זמן המתנה מצטבר לחדר מסוים או צוות. זה תומך בקבלת החלטות כמו הקצאת משאבים, תעדוף בקשות או זיהוי בקשות שעלולות לגרום לעיכובים משמעותיים.



תוצאות:















המלצות וכיוונים להמשך

1. סימולציה - אפשר לפתח סימולציה תהליכית לזיהוי ומיפוי של צווארי בקבוק בתהליכים השונים. לשם כך נדרש מיפוי מלא של התהליך, הסתברויות (על סמך מידע עבר) למעברים בין מחלקות שונות, התפלגות זמני טיפול בכל תחנה, מיפוי המשאבים המשותפים והקצאת משאבים לכל סוג דרישה.